Reservas que não se concretizam: um MVP de pipeline de dados em nuvem para apoio à decisão sobre cancelamentos na hotelaria

Diogo Lopes de Macêdo
Departamento de Engenharia de Produção – Universidade de Brasília (UnB)
Disciplina: Sistemas de Suporte à Decisão – Prof. André Luiz Marques Serrano
Repositório: `https://github.com/lopesmdiogo-1111/mvp-ssd-hotel-cancelamentos`

Resumo

Cancelamentos de reservas são uma das principais fontes de incerteza na gestão de capacidade hoteleira: cada quarto cancelado próximo à data de chegada tende a se tornar capacidade perecível não vendida. Este trabalho desenvolve um *Minimum Viable Product* (MVP) de Sistema de Suporte à Decisão (SSD) que testa a hipótese de que o risco de cancelamento é previsível a partir de atributos conhecidos no momento da reserva – antecedência, canal de venda, política de depósito e histórico do cliente – e de que esse conhecimento permite calibrar políticas de *overbooking* e de depósito por segmento. Utilizou-se o conjunto *Hotel Booking Demand*, disponível no Kaggle, com 119.390 reservas de dois hotéis portugueses entre 2015 e 2017. O pipeline foi construído na plataforma Databricks segundo a arquitetura *medallion* (Bronze, Silver e Gold), com tabelas Delta, modelo dimensional em esquema estrela, catálogo de dados e análise de qualidade por atributo. Os resultados indicam taxa de cancelamento de 41,8% no hotel urbano e 27,8% no resort, crescente com a antecedência da reserva (de 9,6% a 57,0%), e receita potencial associada a cancelamentos de 16,7 milhões de euros no período. Conclui-se que o MVP valida tecnicamente o pipeline e fornece base quantitativa para políticas diferenciadas por segmento, com custo de operação nulo no nível gratuito da plataforma.

Palavras-chave: Sistemas de Suporte à Decisão; Gestão de Receitas; Cancelamento de Reservas; Lakehouse; Esquema Estrela.

1 Introdução

Hotéis operam com capacidade fixa e produto perecível: uma diária não vendida não pode ser estocada. Nesse contexto, a reserva funciona como um compromisso de demanda futura sobre o qual o hotel planeja tarifas, alocação de quartos e mão de obra. Quando uma fração relevante dessas reservas é cancelada – muitas vezes perto da data de chegada –, a capacidade previamente bloqueada retorna ao estoque tarde demais para ser revendida, gerando perda de receita e erro de planejamento.

Para a Engenharia de Produção, trata-se de um problema clássico de gestão de capacidade sob incerteza de demanda. As respostas gerenciais usuais – aceitar mais reservas do que a capacidade (*overbooking*) e exigir depósito não reembolsável – dependem de uma estimativa confiável de quais reservas tendem a ser canceladas. Um Sistema de Suporte à Decisão (SSD) que organize o histórico de reservas permite substituir regras uniformes por políticas diferenciadas por segmento.

Seguindo a lógica de experimentação enxuta de Ries (2011), este trabalho constrói o menor artefato capaz de gerar aprendizado validado sobre a seguinte **hipótese**: *o risco de cancelamento varia de forma sistemática com atributos conhecidos no momento da reserva, de modo que um pipeline de dados em nuvem pode subsidiar políticas de overbooking e de depósito por segmento*. O **objetivo** é desenvolver um pipeline em nuvem, da coleta à análise, que responda às seguintes perguntas de negócio:

Q1 Qual a taxa de cancelamento de cada hotel e como ela varia ao longo dos meses de chegada?
Q2 Como a probabilidade de cancelamento varia com a antecedência da reserva (*lead time*)?
Q3 Quais combinações de segmento de mercado e tipo de depósito concentram as maiores taxas de cancelamento?
Q4 Qual a receita potencial associada às reservas canceladas, por hotel e por mês, e qual parcela foi cancelada com menos de sete dias de antecedência da chegada?

Q5 Clientes recorrentes e clientes com cancelamentos anteriores apresentam comportamento distinto, a ponto de justificar tratamento diferenciado?

As perguntas foram formuladas antes da escolha final da base, conforme a orientação do MVP, e são mantidas íntegras mesmo quando não integralmente respondidas. O texto apresenta a revisão da literatura (Seção 2), a metodologia (Seção 3), os resultados e sua discussão (Seção 4) e as conclusões com a autoavaliação (Seção 5).

2 Revisão da literatura

Sistemas de Suporte à Decisão. Sprague (1980) estruturou os SSD em três subsistemas – dados, modelos e diálogo – e os caracterizou como sistemas voltados a problemas semiestruturados, nos quais o julgamento humano permanece central. Power (2002) classificou os SSD conforme o componente dominante, destacando os *data-driven DSS*, cuja utilidade decorre do acesso organizado a grandes volumes de dados históricos. Shim et al. (2002) apontaram a convergência dos SSD com o *data warehousing* e o processamento analítico como tendência estrutural do campo.

Data Warehouse, Data Lake e Lakehouse. Inmon (2005) definiu o *data warehouse* como coleção de dados orientada a assunto, integrada, não volátil e variante no tempo. Kimball e Ross (2013) propuseram a modelagem dimensional, em que tabelas fato registram eventos de negócio em um grão declarado e tabelas de dimensão fornecem o contexto de análise. Os *data lakes* passaram a armazenar dados brutos na nuvem a baixo custo, porém sem garantias transacionais; o Delta Lake (Armbrust et al., 2020) acrescentou transações ACID, versionamento e imposição de esquema sobre arquivos Parquet, e o paradigma *lakehouse* (Armbrust et al., 2021) propõe unificar o armazenamento do *lake* e a gestão do *warehouse* em uma só plataforma. O processamento é feito pelo Apache Spark (Zaharia et al., 2016), motor do Databricks.

Qualidade de dados. Wang e Strong (1996) mostraram que qualidade de dados é um conceito multidimensional, definido pela adequação ao uso. Batini e Scannapieco (2006) sistematizaram as dimensões de completude, unicidade, consistência, acurácia e atualidade, que fundamentam a análise por atributo da Seção 4.1.

Gestão de receitas e cancelamentos. Kimes (1989) caracterizou o *yield management* como ferramenta para empresas de serviço com capacidade restrita, demanda segmentável e produto perecível – condições típicas da hotelaria. Talluri e van Ryzin (2004) formalizaram o *overbooking* como decisão que equilibra o custo de quartos vazios e o custo de recusar hóspedes com reserva, decisão que depende diretamente da distribuição das taxas de cancelamento. Antonio et al. (2017) demonstraram que cancelamentos podem ser previstos com boa acurácia a partir de atributos da reserva, e Antonio et al. (2019) publicaram os dados utilizados neste trabalho.

3 Metodologia

3.1 Base de dados, licença e coleta

Utilizou-se o conjunto *Hotel Booking Demand* (Mostipak, 2020), versão no Kaggle dos dados publicados por Antonio et al. (2019). O arquivo único `hotel_bookings.csv` contém 119.390 reservas e 32 atributos de dois hotéis em Portugal – um resort (H1, 40.060 reservas) e um hotel urbano (H2, 79.330 reservas) –, com chegadas previstas entre julho de 2015 e agosto de 2017. A publicação original adota licença CC BY 4.0, que autoriza redistribuição e uso derivado com atribuição. Os dados não contêm identificadores pessoais: hotéis, agentes e empresas aparecem apenas como códigos numéricos e o cliente é descrito por país e tipo, de forma compatível com a LGPD (Brasil, 2018). A coleta foi feita por *download* no site do Kaggle em 09/11/2026 (16,1 MB) e o arquivo foi enviado a um *Volume* do Unity Catalog no Databricks. A Tabela 1 agrupa os atributos de origem por destino no modelo.

3.2 Arquitetura do pipeline

O pipeline foi implementado na versão gratuita do Databricks, em notebooks PySpark e SQL orquestrados por um *Job* com três tarefas dependentes, segundo a arquitetura *medallion* (Figura 1). Na camada **Bronze**, o CSV é lido sem alteração semântica e persistido como tabela Delta, acrescida das colunas de linhagem

Tabela 1 – Grupos de atributos do arquivo de origem e destino no modelo dimensional.

Grupo	Atributos de origem (exemplos)	Destino
Hotel	`hotel`	`dim_hotel`
Datas	`arrival_date_year`, `_month`, `_day_of_month`, `_week_number`	`dim_tempo`
Canal	`market_segment`, `distribution_channel`, `deposit_type`, `agent`	`dim_canal`
Cliente	`country`, `customer_type`, `is_repeated_guest`, `previous_cancellations`	`dim_perfil_cliente`
Medidas	`is_canceled`, `lead_time`, `adr`, noites, hóspedes, `booking_changes`	`fato_reserva`
Status	`reservation_status`, `reservation_status_date`	Validação / `fato_reserva`
Excluído	`company` (majoritariamente nulo)	Não utilizado

`_arquivo_origem` e `_data_ingestao`. Na **Silver**, aplicam-se tipagem, padronização, deduplicação e regras de negócio. Na **Gold**, constrói-se o modelo dimensional consumido pelas análises. Todas as tabelas residem no catálogo `mvp_hotel`, garantindo a persistência em nuvem exigida pelo MVP.

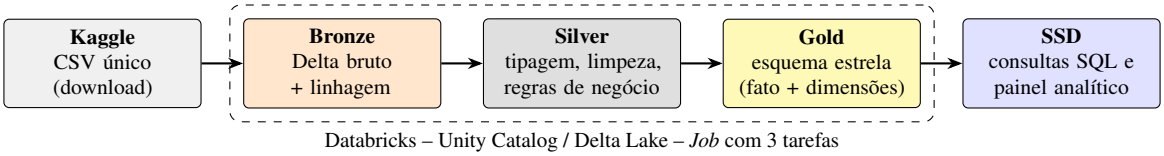


Figura 1 – Arquitetura *medallion* do pipeline implementado.

3.3 Modelagem dimensional e catálogo de dados

Adotou-se um esquema estrela (Kimball e Ross, 2013) com a tabela `fato_reserva`, cujo grão é *uma reserva* (Figura 2). Como a origem é um arquivo único e desnormalizado, as dimensões foram derivadas por projeção dos atributos distintos e receberam chaves substitutas (*surrogate keys*). A dimensão de canal reúne segmento, canal de distribuição, tipo de depósito e agente, pois esses atributos são analisados em conjunto em **Q3**. O catálogo completo, com tipo, descrição, domínio, obrigatoriedade e linhagem de cada atributo, está no diretório `/catalogo` do repositório; a Tabela 2 apresenta as medidas da tabela fato.

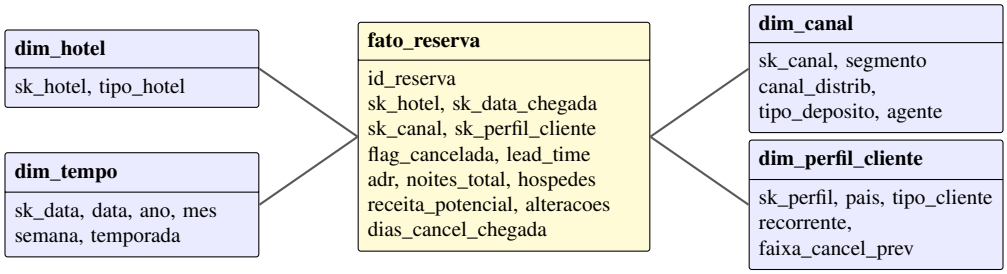


Figura 2 – Esquema estrela da camada Gold.

Tabela 2 – Extrato do catálogo de dados: medidas da tabela `fato_reserva`.

Atributo	Tipo	Descrição	Domínio	Linhagem
`flag_cancelada`	booleano	Reserva cancelada pelo cliente	{0, 1}	`is_canceled`
`lead_time`	inteiro	Dias entre a reserva e a chegada prevista	0 a 737	`lead_time`
`adr`	decimal	Diária média da reserva (EUR)	0 a 510	`adr`, após tratamento de anomalias
`noites_total`	inteiro	Total de noites reservadas	0 a 69	`stays_in_weekend_nights` + `stays_in_week_nights`
`hospedes`	inteiro	Adultos, crianças e bebês	1 a 55	`adults` + `children` + `babies`
`receita_potencial`	decimal	Receita da reserva se concretizada (EUR)	≥ 0	`adr` × `noites_total`

3.4 Transformação e carga

As regras de negócio aplicadas na passagem Bronze → Silver → Gold foram: (i) composição da data de chegada a partir de ano, mês (convertido de nome para número) e dia; (ii) conversão dos textos `"NULL"` de `agent` e `country` em nulos reais, rotulados como `sem_agente` e `desconhecido` nas dimensões; (iii) preenchimento com zero dos poucos nulos de `children`; (iv) exclusão, com registro em tabela de rejeitados, de reservas sem hóspedes e de diárias negativas ou implausíveis; (v) padronização de `meal`, unificando `Undefined` e `SC` (sem refeição), conforme a documentação original; (vi) cálculo de `receita_potencial`, aplicável apenas a reservas com ao menos uma noite; (vii) derivação da faixa de cancelamentos anteriores (0, 1, 2 ou mais); e (viii) cálculo de `dias_cancel_chegada`, diferença entre a data de chegada e `reservation_status_date`, que nas reservas canceladas registra a data do cancelamento. Linhas idênticas não foram removidas, pois a base não traz identificador de reserva e reservas de grupo legítimas podem coincidir em todos os atributos; foi criado o identificador sequencial `id_reserva`. A carga é feita em modo *overwrite* idempotente, de forma que a reexecução do *Job* reproduz o mesmo estado.

3.5 Análise

A análise de qualidade examinou cada atributo nas dimensões de Batini e Scannapieco (2006). As perguntas de negócio foram respondidas por consultas SQL sobre a camada Gold. Para **Q2**, a associação entre antecedência e cancelamento foi verificada pelo teste qui-quadrado entre faixas de *lead time* e status ($\alpha = 0{,}05$). Em **Q3** e **Q5**, consideraram-se apenas grupos com ao menos 200 reservas, para evitar taxas instáveis.

4 Resultados e discussão

4.1 Qualidade dos dados

A Tabela 3 resume os problemas encontrados e o tratamento adotado. Os atributos não listados apresentaram completude integral e valores dentro do domínio declarado. A verificação de consistência entre `is_canceled` e `reservation_status` confirmou que toda reserva marcada como cancelada tem status `Canceled` ou `No-Show`; por isso, `reservation_status` não foi usado como atributo explicativo, já que é registrado após o desfecho e não está disponível no momento da reserva.

Tabela 3 – Principais problemas de qualidade identificados e tratamento.

Dimensão	Atributo	Problema observado	Tratamento
Completude	`company`	94,3% de valores `"NULL"`	Atributo descartado
Completude	`agent`	13,7% de valores `"NULL"`	Rótulo `sem_agente`
Completude	`country`	488 valores `"NULL"` (0,4%)	Rótulo `desconhecido`
Completude	`children`	4 nulos	Preenchido com zero
Acurácia	`adults`, `children`, `babies`	180 reservas com zero hóspedes	Excluídas (rejeitados)
Acurácia	`adr`	1 valor negativo e 1 acima de 1.000 EUR	Excluídos (rejeitados)
Conformidade	`meal`	Categorias `Undefined` e `SC` equivalentes	Unificadas
Unicidade	todas	31.994 linhas idênticas; sem chave natural	Mantidas; criado `id_reserva`

Após os tratamentos, 182 registros (0,15%) foram enviados à tabela de rejeitados e a tabela fato ficou com 119.208 reservas, o mesmo número da camada Silver, sem perdas nas junções. A decisão de manter linhas idênticas é a mais sensível do trabalho: removê-las reduziria a base e alteraria as taxas de cancelamento de alguns segmentos, o que é discutido na autoavaliação.

4.2 Respostas às perguntas de negócio

Q1 – Taxa de cancelamento. O hotel urbano cancelou 41,8% das reservas, contra 27,8% do resort. No resort, a taxa acompanha a sazonalidade: vai de 14,8% em janeiro a 31–33% entre junho e setembro. No hotel urbano, a taxa é alta o ano todo, entre 37,1% e 46,3%, com pico de abril a junho. A diferença de

nível e de padrão sazonal entre os hotéis indica que uma política única de *overbooking* para a rede seria inadequada.

Q2 – Antecedência. A Tabela 4 mostra que a taxa de cancelamento cresce com a antecedência, passando de 9,6% nas reservas feitas com até 7 dias para 57,0% nas feitas com mais de 180 dias ($\chi^2 = 11.914{,}3$; 4 graus de liberdade; $p < 0{,}001$). Reservas antecipadas ficam expostas por mais tempo a mudanças de planos e à busca por tarifas melhores, o que é coerente com a literatura de gestão de receitas (Talluri e van Ryzin, 2004).

Tabela 4 – Taxa de cancelamento por faixa de antecedência (**Q2**).

Antecedência da reserva	Reservas	Taxa de cancelamento	Diária média (EUR)
0 a 7 dias	19.635	9,6%	90,5
8 a 30 dias	18.945	27,9%	108,2
31 a 90 dias	29.528	37,7%	106,4
91 a 180 dias	26.420	44,7%	109,2
Acima de 180 dias	24.680	57,0%	93,0

Q3 – Segmento e depósito. O resultado mais marcante contraria a intuição (Tabela 5): as reservas com depósito não reembolsável apresentaram taxas de cancelamento próximas de 100% (99,9% em operadoras *offline* e 99,3% em grupos), contra no máximo 36,7% nas combinações sem depósito. Essas reservas são feitas com grande antecedência (189 a 232 dias, em média), o que sugere bloqueios de quartos por operadoras e grupos, posteriormente liberados, e não decisões de hóspedes individuais. Uma explicação alternativa é que o campo registre a política contratada, e não a cobrança efetiva do depósito. Em qualquer caso, o achado exige validação com o hotel antes de fundamentar decisões. Entre as reservas sem depósito, o maior risco está no segmento *Online TA* (36,7%), que é também o maior em volume.

Tabela 5 – Combinações de segmento e depósito com maior taxa de cancelamento (mín. 200 reservas) (**Q3**).

Segmento	Depósito	Reservas	Taxa de cancel.	Antecedência média
Offline TA/TO	Non Refund	5.005	99,9%	189
Groups	Non Refund	9.172	99,3%	232
Corporate	Non Refund	334	93,4%	69
Online TA	No Deposit	56.334	36,7%	83
Groups	No Deposit	10.488	28,3%	148

Q4 – Receita em risco. As reservas canceladas somaram receita potencial de 16,72 milhões de euros no período, 65% dela no hotel urbano (10,88 milhões) e 35% no resort (5,84 milhões). No resort, a perda concentra-se no verão: julho e agosto de 2017 responderam, juntos, por 1,52 milhão de euros. Do total cancelado, 10,7% da receita potencial foi cancelada a menos de sete dias da chegada, quando a chance de revenda é baixa; essa parcela foi de 12,4% no hotel urbano e de 7,3% no resort. Como a base não informa se o quarto foi revendido, a receita potencial é um limite superior da perda efetiva.

Q5 – Histórico do cliente. Clientes recorrentes cancelaram 14,7% das reservas, contra 37,8% dos novos. Clientes com exatamente um cancelamento anterior cancelaram 94,4% das reservas (6.048 casos), mas a taxa cai para 52,9% entre os que têm dois ou mais (431 casos). A relação não é monotônica, o que sugere que parte desses registros também corresponde a reservas de grupos e operadoras, e não a hóspedes individuais. O histórico é um sinal útil, mas cobre uma parcela pequena da base: apenas 3,1% das reservas são de recorrentes.

4.3 Discussão geral

Em conjunto, as respostas sustentam a hipótese do MVP: o cancelamento não se distribui ao acaso, mas varia de forma sistemática com o hotel (**Q1**), a antecedência (**Q2**), o segmento (**Q3**) e o histórico do cliente (**Q5**). Para o gestor, a decisão sugerida é substituir a margem uniforme de *overbooking* por margens por segmento e faixa de antecedência, iguais à taxa histórica de cancelamento de cada célula, e investigar, com a equipe comercial, as reservas não reembolsáveis de operadoras e grupos, que concentram cancelamentos

quase totais. Quanto à viabilidade financeira, o pipeline processou todo o volume no nível gratuito, com execução do *Job* em 1 minuto e 33 segundos; em operação contínua, o custo seria dominado por um *cluster* pequeno agendado diariamente. As associações observadas são descritivas e não causais, e os dois hotéis não representam o mercado hoteleiro em geral.

5 Conclusão e autoavaliação

Este trabalho desenvolveu um MVP de Sistema de Suporte à Decisão para gestão de cancelamentos na hotelaria, com pipeline completo na plataforma Databricks, modelo dimensional em esquema estrela, catálogo de dados com domínios e linhagem e análise de qualidade por atributo. A viabilidade técnica foi demonstrada pelo pipeline executável ponta a ponta; a financeira, pelo custo nulo no nível gratuito; e a desejabilidade, pelas respostas que apontam decisões concretas de *overbooking* e depósito.

Autoavaliação. As perguntas **Q1**, **Q2**, **Q3** e **Q5** foram respondidas. A **Q4** foi respondida em parte, pois a base não indica se os quartos cancelados foram revendidos, impedindo medir a perda efetiva. As principais limitações são o período curto (2015–2017), a restrição a dois hotéis de um único país e a ausência de chave natural de reserva. Se recomeçasse o trabalho, investigaria com mais cuidado as linhas idênticas, comparando os resultados com e sem deduplicação, e incluiria desde o início uma dimensão de data de cancelamento. Para transformar o MVP em solução de uso contínuo, seriam necessários: ingestão incremental integrada ao sistema de reservas, testes automatizados de qualidade a cada carga, um modelo preditivo de probabilidade de cancelamento por reserva e um painel para a equipe de gestão de receitas.

Referências

ANTONIO, N.; ALMEIDA, A.; NUNES, L. Predicting hotel booking cancellations to decrease uncertainty and increase revenue. **Tourism & Management Studies**, v. 13, n. 2, p. 25–39, 2017.

ANTONIO, N.; ALMEIDA, A.; NUNES, L. Hotel booking demand datasets. **Data in Brief**, v. 22, p. 41–49, 2019.

ARMBRUST, M. et al. Delta Lake: high-performance ACID table storage over cloud object stores. **Proceedings of the VLDB Endowment**, v. 13, n. 12, p. 3411–3424, 2020.

ARMBRUST, M.; GHODSI, A.; XIN, R.; ZAHARIA, M. Lakehouse: a new generation of open platforms that unify data warehousing and advanced analytics. In: CONFERENCE ON INNOVATIVE DATA SYSTEMS RESEARCH (CIDR), 11., 2021. **Proceedings** [...]. 2021.

BATINI, C.; SCANNAPIECO, M. **Data quality**: concepts, methodologies and techniques. Berlin: Springer, 2006.

BRASIL. Lei n.º 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**, Brasília, DF, 15 ago. 2018.

INMON, W. H. **Building the data warehouse**. 4. ed. Indianapolis: Wiley, 2005.

KIMBALL, R.; ROSS, M. **The data warehouse toolkit**: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

KIMES, S. E. Yield management: a tool for capacity-constrained service firms. **Journal of Operations Management**, v. 8, n. 4, p. 348–363, 1989.

MOSTIPAK, J. **Hotel booking demand**. Kaggle, 2020. Disponível em: `https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand`. Acesso em: 9 nov. 2026.

POWER, D. J. **Decision support systems**: concepts and resources for managers. Westport: Quorum Books, 2002.

RIES, E. **The lean startup**: how today's entrepreneurs use continuous innovation to create radically successful businesses. New York: Crown Business, 2011.

SHIM, J. P. et al. Past, present, and future of decision support technology. **Decision Support Systems**, v. 33, n. 2, p. 111–126, 2002.

SPRAGUE, R. H. A framework for the development of decision support systems. **MIS Quarterly**, v. 4, n. 4, p. 1–26, 1980.

TALLURI, K. T.; VAN RYZIN, G. J. **The theory and practice of revenue management**. New York: Springer, 2004.

WANG, R. Y.; STRONG, D. M. Beyond accuracy: what data quality means to data consumers. **Journal of Management Information Systems**, v. 12, n. 4, p. 5–33, 1996.

ZAHARIA, M. et al. Apache Spark: a unified engine for big data processing. **Communications of the ACM**, v. 59, n. 11, p. 56–65, 2016.